

Der NASA-Schraubendreher: Eine Engine für strukturelle Ausrichtung zur Produktidentifikation

Wie eine einzige Engine für strukturelle Ausrichtung sowohl Sprach- als auch Chat-Produktidentifikation ermöglicht – und Retouren reduziert, Verkäufe steigert und Loyalität aufbaut, indem sie die Identifikationslücke schließt.

1. Die Eröffnungsszene

Ein Kunde ruft an. Er braucht ein Teil. Er beschreibt es.

„Ich brauche eine Bremsscheibe für einen 1997 Toyota Tacoma, vorne Beifahrerseite, mit dem ABS-Ring.“

oder

„Ich suche Schlaghosen aus Schlagjeans – natürlich – kein Polyester – mit Gürtelschlaufen, Paisleymuster.“

oder

„Es ist dieser Titan-Drehmomentschraubendreher, den die NASA bei der Marsmission verwendet hat, mit dem roten eloxierten Ring und der extremen Temperaturbeständigkeit.“

Die Person am anderen Ende der Leitung – oder der Chatbot am anderen Ende des Chatfensters – gibt ein paar Schlüsselwörter in eine Suchleiste ein. Eine Liste von Kandidaten erscheint. Sie raten. Der Kunde rät. Ein Teil wird versendet.

Allzu oft ist es das falsche Teil.

Der Kunde schickt es zurück. Das Callcenter trägt die Versandkosten. Das Lager erhält ein Teil, das nicht wieder ins Regal gestellt werden kann, weil niemand positiv identifizieren kann, was es ist – das SKU-Etikett fehlt, die Schrumpffolie ist ab, und das Teil sieht aus wie hundert andere Teile. Das Teil wird als „nicht identifiziert“ eingestuft oder verschrottet. Die Kosten der Retoure sind höher als die Gewinnspanne des ursprünglichen Verkaufs.

Dieser Kreislauf wiederholt sich Milliarden Mal im Jahr in jeder Branche, die physische Produkte verkauft. Retouren kosten US-Einzelhändler jährlich über eine Billion Dollar. Die häufigste Ursache: Der Kunde hat den falschen Artikel erhalten. Der größte Einzelfaktor für falsche Artikel: Der Identifikationsschritt – die Übereinstimmung zwischen der Beschreibung des Kunden und dem Katalog – wurde von einem Menschen oder einem Chatbot mit einer Schlagwortsuche durchgeführt.

Doch der Schaden beschränkt sich nicht auf Retouren. Jedes Mal, wenn ein Kunde abspringt, weil das System das beschriebene Teil nicht finden konnte, geht ein Verkauf verloren. Jedes Mal, wenn sie das falsche Teil erhalten, schwindet ihr Vertrauen und sie gehen woanders hin. Und jedes Mal, wenn ein Callcenter einen Fachexperten hinzuziehen muss, um die Beschreibung eines Kunden manuell mit dem Katalog zu vergleichen, verdreifachen sich die Kosten dieser Interaktion.

Dieses Papier beschreibt ein System, das alle vier Probleme gleichzeitig löst: weniger Retouren, mehr Verkäufe, stärkere Kundenbindung und drastisch geringere Kosten für Experten-Eskalationen.

2. Das gleiche Problem, zwei Kanäle

Ob der Kunde per Sprach (Telefonanruf) oder Text (Chatbot, Webformular, E-Mail) zu Ihnen gelangt – das zugrunde liegende Problem ist identisch.

	Telefonanruf	Chat / Text
Eingabe	Sprach-zu-Text-Transkription (verrauscht)	Getippter Text (sauberer)
Beschreibungsstil	Fragmentarisch, konversationell, Füllwörter	Oft fragmentarisch, manchmal kopiert-eingefügt
Kundenerwartung	„Ich habe es gesagt, du solltest es wissen“	„Ich habe es getippt, du solltest es wissen“

Aktuelle Fehlerart	Agent hört falsch oder sucht falsch	Chatbot zeigt „keine Ergebnisse“ oder falsche Ergebnisse
--------------------	-------------------------------------	--

Das strukturelle Problem ist in beiden Kanälen dasselbe: Der Kunde beschreibt ein Produkt in natürlicher Sprache, und das System muss diese Beschreibung auf genau eine SKU in einem Katalog mit Tausenden abbilden.

Die Lösung ist in beiden Kanälen dieselbe: eine deterministische Ausrichtungs-Engine, die das, was der Kunde beschrieben hat – Merkmal für Merkmal – mit jedem Produkt im Katalog vergleicht. Der Sprachkanal fügt vorne einen Sprach-zu-Text-Schritt hinzu; der Chatkanal nicht. Alles danach ist identisch.

3. Warum aktuelle Ansätze scheitern

Drei Ansätze dominieren heute die Produktidentifikation. Jeder hat eine strukturelle Obergrenze.

Schlagwortsuche gleicht die Wörter des Kunden mit Produkttiteln und -beschreibungen ab. Sie scheitert an Synonymen („Schlaghose“ vs. „ausgestellt“), an spärlichen Beschreibungen (der Kunde nennt drei von zwanzig Merkmalen) und an Teilübereinstimmungen, die richtig aussehen, aber falsch sind (eine Bremsscheibe für das gleiche Baujahr und Modell, aber die falsche Achsseite).

Embedding-Ähnlichkeit kommt in die richtige Nachbarschaft. Sie kann sagen, dass „Titan-Drehmomentschraubendreher“ im gleichen Vektorraum liegt wie „Drehmomentschrauber“ und „Titan-Werkzeug“. Sie kann jedoch nicht den Unterschied zwischen einem Drehmomentschrauber für Vakuummontage und einem für Atmosphärengebrauch erkennen – die Embeddings sind zu nah beieinander. Sie kann keine strukturellen Einschränkungen durchsetzen. Sie liefert Kandidaten, aber sie verifiziert keine Übereinstimmungen.

Menschliche Agenten sind derzeit die leistungsfähigste eingesetzte Lösung, aber diese Fähigkeit ist teuer, inkonsistent über verschiedene Schichten und geht zur Tür hinaus, wenn der Agent das Unternehmen verlässt. Wenn der Agent das Produktkatalog nicht gut genug kennt – was bei umfangreichen, sich ständig ändernden Katalogen die Regel ist – eskaliert er den Anruf an einen Fachexperten (SME). Dieser Experte kann ein Produktspezialist, ein leitender Ingenieur oder ein erfahrener Verkäufer sein, der den Katalog auswendig kennt. Der SME hört sich die Kundenbeschreibung an, vergleicht sie gedanklich mit dem Produktsortiment und identifiziert die richtige SKU. Dieser Prozess kann 10–20 Minuten pro Anruf dauern, kostet das 3- bis 5-fache einer Standard-Agenten-Interaktion und ist nicht skalierbar. Jede SME-Stunde, die für Identifikation aufgewendet wird, ist eine Stunde, die nicht für Produktschulungen, Qualitätssicherung oder wertvolle Kundenbeziehungen zur Verfügung steht.

Chatbots, die dieselben Schlagwort- oder Embedding-Ansätze verwenden, scheitern still – sie geben „keine Ergebnisse“ oder den falschen Artikel mit einem Konfidenzwert zurück, den der Kunde nicht interpretieren kann. Wenn ein Chatbot scheitert, bricht der Kunde entweder den Kauf ab (Umsatzverlust) oder eskaliert an einen menschlichen Agenten (Kosten + Verzögerung). Beide Ergebnisse sind schlecht.

Allen drei Ansätzen ist der gleiche strukturelle Fehler gemeinsam: Sie behandeln Produktidentifikation als ein Ranking-Problem und nicht als ein Ausrichtungsproblem.

3a. Vier Einsatzmodi

Dieselbe Ausrichtungs-Engine kann in vier verschiedenen Konfigurationen eingesetzt werden. Die Engine selbst ändert sich nicht – nur die Ein- und Ausgabewandler und ob ein menschlicher Agent im Kreis ist.

Modus 1: Chatbot (vollautomatisch, Text)

- **Eingabe:** Kunde tippt in ein Chatfenster oder Webformular

- **Ausgabe:** Textbestätigung, Rückfrage oder GapReport
- **Menschliche Beteiligung:** Keine (außer der Kunde verlangt Eskalation)
- **Am besten geeignet für:** E-Commerce-Websites, Self-Service-Portale, Messaging-Apps

Das System übernimmt die gesamte Interaktion. Wenn die Beschreibung des Kunden genau einer SKU entspricht, gibt das System die Bestätigung zurück und fragt nach einer Kaufentscheidung. Wenn mehrere Kandidaten übereinstimmen, stellt das System eine Rückfrage. Wenn nichts übereinstimmt, erklärt das System, warum. Es wird kein menschlicher Agent benötigt – und keine SME-Eskalation ist erforderlich.

Modus 2: Vollautomatisches Telefonsystem (TTS/STT)

- **Eingabe:** Kunde spricht; STT-Engine transkribiert
- **Ausgabe:** TTS liest Bestätigung, Rückfrage oder GapReport vor
- **Menschliche Beteiligung:** Keine
- **Am besten geeignet für:** Hochvolumige Callcenter, in denen die meisten Anfragen einfache Teilesuchen sind

Das System ersetzt den menschlichen Agenten vollständig. Der Kunde spricht seine Beschreibung. Das System transkribiert sie, führt die Ausrichtung durch und liest das Ergebnis vor. Der Kunde kann „Ja, das ist es“ sagen, und die Bestellung wird automatisch aufgegeben. Dieser Modus verkürzt die Bearbeitungszeit von Minuten auf Sekunden und macht die Einbeziehung von SMEs bei Routineidentifikationen überflüssig.

Modus 3: Menschlicher Callcenter-Agent (unterstützt)

- **Eingabe:** Kunde spricht mit einem menschlichen Agenten
- **Ausgabe:** Das System zeigt dem Agenten die beste Übereinstimmung, Bestätigungsdetails und GapReport
- **Menschliche Beteiligung:** Agent interagiert mit dem Kunden; das System bietet Echtzeit-Entscheidungsunterstützung

- **Am besten geeignet für:** Komplexe Anfragen, hochwertige Teile oder Kunden, die lieber mit einer Person sprechen

Der menschliche Agent bleibt im Gespräch, aber das System fungiert als Echtzeit-Entscheidungsunterstützungstool. Während der Kunde das Teil beschreibt, tippt der Agent die wichtigsten Merkmale in eine Suchoberfläche (oder das System hört mit und erstellt die Konzeptdefinition automatisch). Das System führt die Ausrichtung durch und präsentiert dem Agenten die beste Übereinstimmung, einschließlich einer strukturierten Bestätigungsvorlage, die der Agent dem Kunden vorlesen kann. Der Agent kümmert sich weiterhin um Preise, Versandoptionen und Ausnahmen. Dieser Modus reduziert die Bearbeitungszeit des Agenten, eliminiert Rätselraten und macht eine Eskalation zu einem SME praktisch überflüssig – das System verfügt bereits über das Produktwissen, das der SME hätte.

Modus 4: Hybrid – Automatisierung vorne mit menschlicher Eskalation

- **Eingabe:** Kunde spricht; automatisches System (TTS/STT) übernimmt die erste Interaktion
- **Ausgabe:** Bei Fehlübereinstimmung oder Mehrdeutigkeit wird der Anruf an einen menschlichen Agenten mit vollständigem Kontext eskaliert
- **Menschliche Beteiligung:** Nur wenn die Automatisierung nicht auflösen kann – der Agent übernimmt mit einem vollständigen GapReport
- **Am besten geeignet für:** Optimierung der Automatisierungseinsparungen mit Rückfallebene für Randfälle

Dies ist die kosteneffizienteste Konfiguration für hochvolumige Callcenter, die nicht 100 % der Anrufe automatisieren können. Das automatische System übernimmt den Identifikationsschritt. Wenn es eine einzige Übereinstimmung findet, bietet es die Bestätigung an und schließt die Bestellung ab. Wenn es mehrere Übereinstimmungen findet, stellt es Rückfragen. Wenn es keine Auflösung findet (GapReport), übergibt es den Anruf an einen menschlichen Agenten – aber es sendet den GapReport zusammen mit dem Anruf. Der Agent sieht genau, was der Kunde beschrieben hat und welche Merkmale zu

keiner SKU passten. Der Agent muss nicht bei Null anfangen – und muss fast nie zu einem SME eskalieren, da der GapReport bereits die strukturierte Argumentation enthält, die ein SME liefern würde.

Die Engine ist dieselbe

Alle vier Modi verwenden dieselbe Ausrichtungs-Engine, Lexika, Level-1/Level-2-Entscheidungslogik und GapReport-Generierung. Die einzigen Unterschiede sind:

- Welcher Wandler am Eingang sitzt (STT für Sprache, Rohtext für Chat oder ein menschliches Eintippen von Merkmalen in eine Konsole)
- Welcher Wandler am Ausgang sitzt (TTS für Sprache, Text für Chat oder eine visuelle Anzeige für einen Agenten)
- Ob ein menschlicher Agent im Kreis ist (Modi 3 und 4) oder nicht (Modi 1 und 2)

Das bedeutet, Sie können heute Modus 1 einführen, im nächsten Quartal Modus 2 hinzufügen und später auf Modus 4 upgraden – alles auf derselben Codebasis.

4. Die strukturelle Lösung: Zwei Abgleich-Ebenen

Das System verwendet eine zweischichtige Architektur. Die erste Schicht (Level 1) ist schnell, günstig und erledigt die meisten Fälle. Die zweite Schicht (Level 2) ist langsamer, aber strukturell verifizierbar, und wird nur aufgerufen, wenn die Einsätze hoch sind.

Level 1: Embedding-Cosinus-Ähnlichkeit + LLM-Entscheider

Dies ist der einfachste Ansatz und funktioniert gut für risikoarme oder explorative Anfragen.

1. Die Beschreibung des Kunden wird in einen Embedding-Vektor umgewandelt.
2. Cosinus-Ähnlichkeit findet die 10–20 ähnlichsten SKUs aus dem Katalog.

3. Ein LLM vergleicht die Kundenbeschreibung mit jeder Kandidaten-Produktbeschreibung und wählt die beste Übereinstimmung aus (oder gibt „keine Übereinstimmung“ zurück).

Diese Pipeline ist schnell (~200 ms), günstig und erfordert keine Ontologie-Entwicklung. Es ist der gleiche Ansatz, den viele E-Commerce-Chatsysteme heute verwenden. Für das Stöbern, für preiswerte Artikel und für Kunden, die noch nicht kaufbereit sind, ist das ausreichend.

Es hat jedoch bekannte Schwächen:

- Das LLM kann halluzinieren oder subtile Unterschiede übersehen (vorne vs. hinten, links vs. rechts).
- Das LLM produziert einen Absatz natürlicher Sprache, keine strukturierte Aufzeichnung. Sie können nicht überprüfen, warum es einen bestimmten Kandidaten gewählt hat.
- Dieselbe Kundenbeschreibung kann aufgrund der Nichtdeterminiertheit des LLMs an verschiedenen Tagen unterschiedliche Ergebnisse liefern.

Level 2: SOAM – Structural Ontological Alignment Model

Wenn die Einsätze höher sind – das Teil teuer, die Folge einer falschen Übereinstimmung eine Retoure oder ein Sicherheitsrisiko – eskaliert das System zu Level 2. SOAM nimmt dieselbe Kandidatenliste aus dem Embedding-Vorfilter und führt eine deterministische, Slot-für-Slot-strukturelle Ausrichtung gegen das Business Inventory Lexicon durch. Es verlässt sich nicht auf das LLM für den Vergleich. Stattdessen:

- Die Merkmale des Kunden werden in eine dünne Konzeptdefinition extrahiert (IS_A, HAS_PART, HAS_ATTRIBUTE).
- Jede Kandidaten-SKU hat eine vollständige strukturierte Definition im Lexikon.
- SOAM vergleicht jeden belegten Slot. Alle müssen übereinstimmen. Leere Slots sind Platzhalter.

- Das Ergebnis ist ein ProofTrace – eine maschinenverifizierbare Aufzeichnung, welche Merkmale genau übereinstimmten und welche nicht.

Wenn kein Kandidat besteht, zeigt ein GapReport, welcher Slot nicht erfüllt werden konnte, sowie die nächstgelegenen verfügbaren Alternativen.

SOAM geht über einen einzelnen Abgleich hinaus. Da das Lexikon eine Ontologie mit Vererbung ist, kann SOAM die Hierarchie durchlaufen. Wenn der Kunde sagt „Ich brauche eine Bremsscheibe“, weiß SOAM, dass eine Bremsscheibe IS_A Scheibe IS_A Bremsteil IS_A Autoteil ist. Es kann auf jeder Abstraktionsebene abgleichen. Diese Multi-Generations-Tiefe bedeutet, dass SOAM Übereinstimmungen finden kann, die ein flacher LLM-Vergleich übersehen würde – oder Übereinstimmungen ablehnen kann, die ein flacher Vergleich fälschlicherweise akzeptieren würde.

SOAM ist nicht auf die Produktidentifikation beschränkt. Derselbe strukturelle Ausrichtungsprozess kann die Anfrage eines Kunden mit einer Ausschreibung (Request for Proposal, RFP) vergleichen. Eine RFP spezifiziert Anforderungen als eine Menge strukturierter Slots (muss X haben, muss Y unterstützen, muss mit Z zertifiziert sein). SOAM kann das Angebot eines Anbieters Slot für Slot gegen die RFP ausrichten und einen verifizierten Compliance-Bericht erstellen. Dies ist dieselbe Engine, angewendet auf eine andere Domäne.

4a. Vom Produktkatalog zur Ontologie: Wie das System die Transformation automatisiert

Bevor das System die Beschreibung eines Kunden abgleichen kann, muss der Produktkatalog von einer flachen Liste von SKUs in eine strukturierte Ontologie umgewandelt werden – ein Netzwerk von Konzepten, die durch IS_A (Typ von), HAS_PART (Komponenten), HAS_ATTRIBUTE (Eigenschaften) und optional HAS_REASON (Verwendungszweck) verbunden sind. Dies ist das Business Inventory Lexicon.

Diese Transformation ist automatisiert. Dieselbe SOAM-Ausrichtungs-Engine, die Kundenbeschreibungen abgleicht, erfasst und bereichert auch Ihren Katalog. So funktioniert die Pipeline.

Schritt 1: Erfassen des Rohkatalogs

Das System liest Ihre vorhandenen Produktdaten – SKU-Nummern, Titel, Beschreibungen, Spezifikationsblätter, Kategoriebäume – aus jedem beliebigen Format (CSV, XML, Datenbankexport, API-Feed). Es ist keine spezielle Vorbereitung erforderlich.

Schritt 2: Die LLM-zu-Lexikon-Brücke extrahiert Struktur

Ein LLM liest jeden Produkteintrag und schlägt Kandidaten-Slot-Füller vor:

- IS_A: Was für ein Ding ist das? (z. B. torque_driver, brake_rotor, bell_bottom_pant)
- HAS_PART: Welche Komponenten oder Merkmale enthält es? (z. B. ABS_ring, red_anodized_collar, belt_loops)
- HAS_ATTRIBUTE: Welche Eigenschaften hat es? (z. B. material=titanium, color=red, max_temperature=600°F)
- HAS_REASON: Wofür wird es verwendet? (z. B. aerospace_assembly, 1997_Toyota_Tacoma_front_passenger)

Das LLM schlägt vor; das Schema entscheidet. Jeder vorgeschlagene Füller wird gegen das Core Lexicon (1,7 Millionen grundierte Wortbedeutungen) aufgelöst. Synonyme werden automatisch aufgelöst: Wenn Ihr Katalog „flared pants“ sagt und das Core Lexicon „flared“ auf „bell_bottom“ abbildet, normalisiert das System zu „bell_bottom“. Wenn ein vorgeschlagener Füller nicht im Core Lexicon gefunden werden kann, wird er zur Überprüfung markiert, blockiert aber nicht die Erfassung.

Schritt 3: SOAM gleicht jeden Eintrag gegen das Lexikon ab

Die vorgeschlagene Konzeptdefinition durchläuft dieselbe SOAM-Engine, die auch für Kundenanfragen verwendet wird. Aber anstatt gegen ein anderes Konzept abzugleichen, gleicht sie gegen das Core Lexicon ab:

- Der Fingerprint-Vorfilter (Level 1) findet die nächstgelegenen Core-Lexicon-Konzepte für jeden Slot-Füller.
- Die vollständige strukturelle Ausrichtung (Level 2) verifiziert, dass der IS_A-Elternteil im Core Lexicon existiert, dass HAS_PART-Komponenten auf grundierte Konzepte aufgelöst werden und dass HAS_ATTRIBUTE-Werte den erwarteten Eigenschaftstypen entsprechen.
- Wenn die Ausrichtung bestanden wird, wird der Eintrag mit einem ProofTrace, der jede Verknüpfung dokumentiert, in das Business Inventory Lexicon aufgenommen.
- Wenn die Ausrichtung fehlschlägt, erzeugt das System einen GapReport, der genau zeigt, welcher Slot nicht grundiert werden konnte – und ein Mensch kann ihn in Minuten überprüfen und korrigieren.

Schritt 4: Aufbau der Taxonomien

Die IS_A-Hierarchie wird automatisch aufgebaut. Für jede SKU schlägt das LLM einen Elternteil vor. SOAM verifiziert, dass der Elternteil im Core Lexicon existiert und dass der Pfad zu einer semantischen Primzahl endlich ist. Polyhierarchie (mehrere Eltern) wird unterstützt – ein Produkt, das sowohl ein Werkzeug als auch ein sicherheitskritisches Bauteil ist, erhält beide Eltern.

Vorhandene Kategoriestructuren in Ihrem Katalog (z. B. „Werkzeuge > Drehmomentschrauber“) werden genutzt, um erste IS_A-Beziehungen vorzuschlagen. Das System muss nicht bei Null anfangen.

Schritt 5: Kontinuierliche Erfassung

Wenn neue SKUs zum Katalog hinzugefügt werden, durchlaufen sie automatisch dieselbe Pipeline – kein manueller Aufwand. Wenn Produktbeschreibungen aktualisiert werden, wird das System neu erfasst und aktualisiert die Ontologie. Das Business Inventory Lexicon bleibt ohne dedizierte Ontologie-Ingenieure aktuell.

Ergebnis: Von einer flachen Liste zu einer strukturierten Ontologie – automatisch

Vorher (Ihr bestehender Katalog):

SKU	Titel
DRV-3000-XLT	Titan-Drehmomentschrauber
BB-HP-72-P	Schlaghosen

Nachher (automatisch angereichert):

SKU	IS_A	HAS_PART	HAS_ATTRIBUTE	HAS_REASON
DRV-3000-XLT	torque_driver	red_anodized_collar	material=titanium, max_temp=600°F	aerospace_assembly
BB-HP-72-P	bellbottom_pant	belt_loops	material=natural_fiber, pattern=paisley, size=28_waist	vintage_fashion

Die gesamte Anreicherungs-pipeline – vom rohen Katalogexport bis zur vollständig grundierten Ontologie – läuft für einen typischen Katalog mit 50.000 SKUs automatisch in 2–8 Stunden. Eine manuelle Überprüfung ist nur für Randfälle erforderlich, bei denen das LLM einen Begriff nicht auflösen kann oder das Core Lexicon keine Entsprechung hat. Diese Randfälle schrumpfen mit jedem erfassten Katalog, da das Core Lexicon wächst.

5. Level 1 vs. Level 2: Abgleich nach Konsequenz

Das System unterscheidet explizit zwischen zwei Abgleichebenen. Die Wahl zwischen ihnen ist keine Frage der technischen Fähigkeit – sondern der Konsequenz eines Fehlers.

	Level 1 (Einfach)	Level 2 (SOAM)
Kernmethode	Cosinus-Ähnlichkeit + LLM-Vergleich	Slot-für-Slot-strukturelle Ausrichtung

Verwendung	Niedrige Einsätze. Erster Durchlauf. Stöbern. Kunde erkundet.	Hohe Einsätze. Endgültige Verifizierung. Kauf. Compliance.
Geschwindigkeit	~200 ms	~500 ms
Überprüfbarkeit	Keine – LLM-Ausgabe ist ein Absatz	Vollständig – ProofTrace mit Slot-für-Slot-Herkunft
Determiniertheit	Nicht-deterministisch – LLM kann variieren	Deterministisch – gleiche Eingabe, gleiche Ausgabe
Multi-Generations-Tiefe	Nein – LLM vergleicht flache Beschreibungen	Ja – SOAM durchläuft Ontologie-Hierarchie
RFP-/Angebotsabgleich	Nicht anwendbar	Direkt anwendbar – Slot-für-Slot-Compliance
Fehlerkonsequenz	Falscher Behälter (einfach zu beheben), verlorene Browsing-Sitzung (geringe Kosten)	Falsches Teil wird verschickt, Sicherheitsvorfall, regulatorische Strafe
Kosten pro Abfrage	Niedrig (Embedding + kleiner LLM-Aufruf)	Mittel (Ausrichtungsberechnung)

Die Entscheidungsregel: Level 1 für Erkundung und risikoarmes Stöbern. Level 2 für Kaufabsichten, hochwertige Artikel, sicherheitskritische Teile und jede Situation, in der eine falsche Übereinstimmung eine Retoure, ein Compliance-Audit oder einen Vertrauensverlust des Kunden auslösen würde.

Das System standardmäßig auf Level 2, wenn der Kunde explizit kaufen möchte. Es kann auch eine Wahl anbieten: „Ich habe mehrere ähnliche Teile gefunden. Möchten Sie, dass ich überprüfe, welches genau Ihrer Beschreibung entspricht?“ – was Level 2 auslöst.

5a. Ist das Over-Engineering? Eine ehrliche Antwort

Ja, SOAM ist für viele Situationen Over-Engineering. Und das ist beabsichtigt.

Für einen Kunden, der in einem günstigen Büroartikelkatalog stöbert, ist die Level-1-Pipeline (Embedding + LLM) völlig ausreichend. Die Konsequenz, den falschen Hefter auszuwählen, ist trivial. Für diesen Katalog eine vollständige Ontologie aufzubauen, wäre Zeit- und Geldverschwendung.

Aber für einen Kunden, der eine Bremsscheibe für einen 1997 Toyota Tacoma, vorne Beifahrerseite, mit ABS-Ring bestellt, sind die Konsequenzen einer Fehlpaarung: eine Retoure, die 50–100 \$ kostet, ein frustrierter Kunde, der vielleicht nie wieder kommt, und ein potenzielles Sicherheitsrisiko, wenn das Teil falsch eingebaut wird. In diesem Kontext amortisieren sich die Kosten für den Aufbau der Ontologie über Tausende von Transaktionen, und die Kosten eines einzigen Fehlers sind höher als die Kosten der Verifizierung.

Die ehrliche Einordnung ist:

	Level 1 (Einfach)	Level 2 (SOAM)
Geeignet für	Günstige Artikel, exploratives Stöbern, generische Produkte, interne Nutzung	Hochwertige Artikel, sicherheitskritische Teile, regulierte Branchen, kundenorientierte Kaufbestätigungen, RFP-Compliance
Entwicklung	Minimal – keine Ontologie nötig	Mittel – automatisierte Ontologie-Anreicherung + Ausrichtungs-

gsauf wand		Engine
Fehler rate	10–20 % (für niedrige Einsätze akzeptabel)	<1 % (für hohe Einsätze notwendig)
Over- Engin eering ?	Nein – es ist das richtige Werkzeug für den Job	Nur, wenn auf risikoarme Probleme angewendet – aber für hohe Einsätze ist es notwendig

Das System ist darauf ausgelegt, beides zu sein. Es bietet die einfache Pipeline als Standard und eskaliert zur rigorosen Pipeline, wenn die Einsätze es erfordern. Dies ist kein Over-Engineering. Es ist Right-Engineering – die Tiefe der Verifizierung an die Kosten des Irrtums anzupassen.

5b. Ein anderer Ansatz: Eine kurze Liste präsentieren und den Kunden entscheiden lassen

Es gibt einen noch einfacheren Ansatz, der in vielen Kontexten gut funktioniert: Embedding-Ähnlichkeit (mit optionalem Cross-Attention-Reranking) verwenden, um eine kurze Liste von 3–5 Kandidaten zu erstellen, dann dem Kunden die Produktbeschreibungen präsentieren und ihn wählen lassen.

So funktioniert es:

1. Embedding + Cross-Attention-Reranking reduziert Tausende von SKUs auf eine kurze Liste der wahrscheinlichsten Übereinstimmungen.
2. Das System liest oder zeigt den Produktnamen, die Hauptmerkmale und den Preis für jeden Kandidaten an.
3. Der Kunde wählt den aus, den er für richtig hält.

Vorteile:

- Sehr einfach zu implementieren – keine Ontologie, kein LLM-Entscheider, keine Ausrichtungs-Engine.

- Funktioniert gut, wenn der Kunde aufmerksam ist und die kurze Liste klar unterscheidbar ist.
- Gibt dem Kunden ein Gefühl der Kontrolle – er trifft die endgültige Entscheidung.

Nachteile:

- Unaufmerksamkeit des Kunden. Wenn der Kunde in einer lauten Telefonleitung ist, Multitasking betreibt oder abgelenkt ist, kann er den falschen Artikel aus der Kurzliste auswählen. Die Retourenquote sinkt nicht so stark wie bei automatisierter Verifizierung.
- Subtile Unterschiede. Wenn die Kurzliste ähnlich aussehende Artikel mit kritischen Unterschieden enthält (z. B. Bremsscheibe vorne vs. hinten, Links- vs. Rechtsgewinde), bemerkt der Kunde die Unterscheidung in der Produktbeschreibung möglicherweise nicht.
- Keine Prüfspur. Wenn der Kunde den falschen Artikel auswählt und später behauptet, das System habe ihn in die Irre geführt, gibt es keine strukturierte Aufzeichnung dessen, was präsentiert wurde und womit der Kunde einverstanden war.
- Skaliert nicht auf Massenbestellungen. Wenn ein Kunde eine Liste von 50 Artikeln hat (z. B. eine Wartungs-Einkaufsliste für eine Flotte), ist es unpraktisch, für jeden Artikel 3–5 Kandidaten zu präsentieren und den Kunden entscheiden zu lassen. Automatisiertes deterministisches Matching ist erforderlich.

Wann dieser Ansatz ausreicht:

- Günstige Artikel, bei denen eine falsche Wahl nicht teuer ist.
- Erfahrene und fokussierte Kunden (z. B. professionelle Mechaniker, die Routine-Teile bestellen).
- Browsing-Szenarien, in denen der Kunde Optionen erkunden möchte.

Wann SOAM besser ist:

- Hochriskante Artikel, bei denen eine falsche Wahl teuer oder gefährlich ist.
- Abgelenkte oder unerfahrene Kunden.
- Massenbestellungen oder Einkaufslisten, die ein automatisiertes, zeilenweises Matching erfordern.
- Jede Situation, in der eine prüfbare, verifizierbare Übereinstimmungsaufzeichnung erforderlich ist.

Der Ansatz „Präsentieren und den Kunden entscheiden lassen“ ist kein Konkurrent zu SOAM. Er ist eine Ergänzung. Dasselbe System kann eine Kurzliste für risikoarme Abfragen anbieten und für risikoreiche Abfragen auf SOAM-Verifizierung eskalieren. Die Architektur unterstützt dies bereits – Level 1 kann die Kurzliste erstellen, und Level 2 (SOAM) kann aufgerufen werden, um die Auswahl des Kunden zu verifizieren, bevor die Bestellung aufgegeben wird.

5c. Jenseits von Telefon und Chat: Automatischer Abgleich von RFPs, Bestellungen und Bulk-Listen

Die bisher beschriebenen Anwendungsfälle – Sprachanruf, Chatbot, menschlicher Agent, Hybrid – drehen sich alle um die interaktive Echtzeit-Identifikation eines einzelnen Produkts. Aber der Wert von SOAM reicht weit über das Callcenter hinaus.

Dieselbe Engine, die die gesprochene Beschreibung eines Kunden mit einer SKU abgleicht, gleicht auch eine strukturierte Ausschreibung (RFP) mit einem Anbieterangebot oder eine Massen-Einkaufsliste mit einem Produktkatalog ab.

Betrachten Sie die folgenden Szenarien:

RFP-Matching:

Eine Beschaffungsabteilung gibt eine RFP mit 200 Positionen heraus, die jeweils erforderliche Merkmale, Zertifizierungen und Leistungsschwellen spezifizieren. Anbieter antworten mit Angeboten. Ein menschlicher Analyst

muss jede Position mit jedem Angebot vergleichen – ein Prozess, der Tage dauert und fehleranfällig ist. SOAM kann die RFP als strukturierte Menge von Slot-basierten Anforderungen erfassen, jedes Angebot als Menge von Produktdefinitionen erfassen und sie Slot für Slot abgleichen. Die Ausgabe ist eine Compliance-Matrix: Für jede RFP-Position, welche Anbieter alle Slots erfüllen, welche einige erfüllen und welche scheitern. Der GapReport zeigt genau, welche Anforderung nicht erfüllt wurde. Dies ist dieselbe Ausrichtungs-Engine, angewendet auf Dokumente statt Sprache.

Bulk-Bestellungs-Matching:

Ein Flottenwartungsmanager reicht eine Liste von 50 Teilen ein – einige mit Namen, einige mit Beschreibung, einige mit OEM-Nummer – bei einem Händler ein. Das System des Händlers muss jede Position der richtigen SKU zuordnen. Mit SOAM wird die gesamte Liste in Sekunden verarbeitet, Position für Position. Jede Übereinstimmung wird verifiziert und dokumentiert. Das Ergebnis ist eine bestätigte Bestellung ohne manuelle Überprüfung für Routineartikel. Für mehrdeutige Artikel werden sie mit einem GapReport markiert, und nur diese Ausnahmen werden von einem Menschen bearbeitet.

Elektronische Bestellungen / EDI-Feeds:

Viele B2B-Transaktionen kommen als elektronische Bestellungen (POs) oder EDI 850-Dokumente. Diese enthalten Positionsbeschreibungen, die oft nicht mit den Namenskonventionen des Empfängerkatalogs übereinstimmen.

SOAM kann jede Position normalisieren, indem es ihre Beschreibung gegen das Business Inventory Lexicon des Empfängers ausrichtet und eine bestätigte SKU mit einem ProofTrace erzeugt. Dadurch entfällt die Notwendigkeit für menschliche Bestelleingabe-Sachbearbeiter, jede Position manuell zu interpretieren und neu einzugeben – und es fängt Fehlpaarungen ab, bevor die Bestellung ausgeführt wird.

Die zentrale Erkenntnis: SOAM ist keine reine Sprach- oder Chat-Technologie. Es ist eine universelle Ausrichtungs-Engine, die auf jede Eingabe funktioniert, die in strukturierte Slot-Füller zerlegt werden kann – ob diese Eingabe von einem Mikrofon, einem Textfeld, einer API, einem EDI-Feed

oder einer Tabellenkalkulation stammt. Dasselbe Lexikon, derselbe Ausrichtungsalgorithmus, derselbe ProofTrace und GapReport gelten.

Das bedeutet, dass die Investition, die Sie in den Aufbau des Business Inventory Lexicon für Ihr Callcenter tätigen, auch Ihre Beschaffungs-, Bestelleingangs- und RFP-Bewertungssysteme unterstützt. Eine Ontologie, viele Anwendungsfälle.

6. Der Bestätigungs-Loop

Das kritische Interaktionsdesign ist der Bestätigungs-Loop. Ob der Kanal Sprache oder Chat ist, das System liest die spezifischen Merkmale vor, die der Kunde genannt hat, Punkt für Punkt.

Sprache:

„Ich habe die Teilenummer DRV-3000-XLT gefunden. Dies ist ein Titan-Drehmomentschrauber, ausgelegt für extreme Temperaturen, mit einem roten eloxierten Ring. Entspricht das dem, was Sie brauchen?“

Chat:

„Ich habe das Teil DRV-3000-XLT gefunden. Merkmale: Titan-Konstruktion, extreme Temperaturbeständigkeit, roter eloxierter Ring. Bestätigen Sie, dass dies das richtige Teil ist?“

Der Kunde hört – oder liest – seine eigene Beschreibung widergespiegelt. Er kann mit Vertrauen bestätigen. Die Bestätigung ist strukturell verifizierbar: Jedes vom Kunden genannte Merkmal ist im Ausrichtungs-Trace dokumentiert. Wenn sich später herausstellt, dass das Teil falsch war, zeigt die forensische Aufzeichnung genau, welche Merkmale abgeglichen und welche abgeleitet wurden.

Dies ist der Unterschied zwischen „wir denken, das ist, was Sie wollen“ und „wir können beweisen, dass dies das ist, was Sie beschrieben haben“.

Und der Kunde lernt. Nach ein oder zwei erfolgreichen Interaktionen, bei denen das System das richtige Teil beim ersten Mal identifiziert – und es mit

den eigenen Worten des Kunden bestätigt – baut sich Vertrauen auf. Der Kunde hört auf, zu zweifeln. Er kommt zuerst zu Ihrem Kanal zurück, weil er weiß, dass Ihr System ihm Zeit und Frustration erspart. Dies ist Loyalität, die durch Genauigkeit verdient wird, nicht durch Rabatte.

7. Der Retouren-Bonus: Dieselbe Pipeline, ein weiterer Durchlauf

Dieselbe Ausrichtungs-Engine, die ein Teil während des ausgehenden Anrufs oder Chats identifiziert, identifiziert es auch während der Retoure.

Ein retourniertes Teil kommt im Lager an. Das SKU-Etikett fehlt. Die Schrumpffolie fehlt. Das Teil hat Oberflächenrost. Ein Mensch kann es nicht positiv identifizieren. Es wird als „nicht identifiziert“ eingestuft oder verschrottet – ein Totalverlust.

Mit der Ausrichtungs-Engine funktioniert die Retoure anders. Das Lager fotografiert das Teil oder führt es durch eine Sensorstation. Visuelle Merkmale – Geometrie, Markierungen, Abnutzungsmuster – werden extrahiert und in eine dünne Konzeptdefinition umgewandelt. Diese Definition wird gegen den Katalog ausgerichtet. Die Engine gibt zurück: „Dies ist Teilenummer DRV-3000-XLT, mit verifizierten Abweichungen: Oberflächenrost vorhanden, Originalverpackung fehlt.“

Das Teil ist nun positiv identifiziert. Es kann zum richtigen Behälter geleitet werden: Aufbereitung (wenn der Rost behebbar ist), Rezertifizierung (wenn das Teil getestet werden kann) oder Teileverwertung (wenn die Innenteile noch verwertbar sind). Die Kosten der Retoure sinken von „Totalverlust“ auf „Bearbeitungskosten plus Aufbereitung“.

Und der Katalog wird aktualisiert: Eine gebrauchte Variante von DRV-3000-XLT existiert nun mit eigenem Verschleißgrad und fehlender Verpackung. Der nächste Kunde, der dieses Teil sucht, kann die gebrauchte Option mit vollem Herkunftsnachweis zu einem reduzierten Preis angeboten bekommen.

8. Die Architektur (Einseitige Zusammenfassung)

So funktioniert es, Ende-zu-Ende.

Schritt	Was passiert	Sprachkanal	Chat-/Textkanal
0	Katalog-Anreicherung (automatische Einrichtung)	Das System erfasst Ihren Produktkatalog und erstellt das Business Inventory Lexicon mittels LLM-zu-Lexikon-Brücke und SOAM-Ausrichtung.	Gleich – die Anreicherung ist kanalunabhängig.
1	Kunde spricht oder tippt	STT-Engine transkribiert Sprache zu Text	Kunde tippt Text direkt
2	Merkmalsextraktion	LLM extrahiert Produktmerkmale aus transkribiertem Text	Gleiches LLM extrahiert Merkmale aus getipptem Text
3	Konzeptdefinition	Dünne Definition: IS_A, HAS_PART, HAS_ATTRIBUTE	Identisches Ausgabeformat (leere Slots = Platzhalter)
4	Level 1 (schnell) – Einfach	Embedding-Cosinus-Ähnlichkeit + LLM-Entscheider. Von Tausenden auf wenige Kandidaten eingrenzen.	Gleiche Pipeline

5	Level 2 (verifiziert) – SOAM	Slot-für-Slot- strukturelle Ausrichtung. Erzeugt ProofTrace. Durchläuft Ontologie-Hierarchie.	Gleiche Ausrichtung
6	Entscheidung	Einzeltreffer → Bestätigung; mehrere Treffer → Rückfrage; kein Treffer → GapReport	Gleiche Logik
7	Ausgabe	TTS liest Ergebnis vor	Text zeigt Ergebnis an

Das System wählt automatisch Level 1 oder Level 2 basierend auf den Einsätzen der Abfrage. Eine Störanfrage bleibt auf Level 1. Eine Kaufabsicht löst Level 2 aus. Dieselbe Codebasis behandelt beides.

9. Die geschäftlichen Ergebnisse

Metrik	Auswirkung
Retourenquote	Reduziert durch Identifikation des richtigen Teils vor dem Versand
Verkaufskonversion	Erhöht – weniger abgebrochene Suchvorgänge, mehr „Ja, das ist es“-Bestätigungen
Kundenbindung / Loyalität	Höher – Genauigkeit beim ersten Mal schafft Vertrauen; Kunden kehren zu dem Kanal zurück, dem sie vertrauen
First-Call-Resolution	Höher – Kunde bestätigt die Übereinstimmung, bevor die Bestellung aufgegeben wird; keine Nachverfolgung nötig

Agenten-Bearbeitungszeit	Niedriger – das System sucht und verifiziert, nicht der Agent
Schulungszeit für neue Agenten	Von Wochen auf Tage reduziert – das System kodiert Produktwissen
Kosten für Fachexperten-Eskalation (SME)	Drastisch reduziert – das System übernimmt die Identifikation, die zuvor einen Spezialisten erforderte
Reverse-Supply-Chain-Kosten	Niedriger – retournierte Teile werden identifiziert und sortiert, nicht verschrottet
Kundenvertrauen	Höher – Kunde hört/liest seine eigene Beschreibung bestätigt
Kanalkonsistenz	Sprache und Chat verwenden dieselbe Engine; keine Abweichung
Compliance / Prüfbarkeit	Vollständiger ProofTrace für regulierte Branchen und RFP-Matching
Effizienz in Beschaffung / Bestelleingang	Bulk-RFP-Matching und PO-Positionsverifizierung reduzieren manuellen Aufwand um 80 %+

9a. Marktchance und Verteidigungsfähigkeit

Das Problem, das SOAM löst, ist kein Nischenproblem. Es ist eine strukturelle Ineffizienz, die in jedem Unternehmen steckt, das physische Produkte verkauft, beschafft oder vertreibt. Der adressierbare Markt ist riesig, das Timing ist richtig, und die Verteidigungsfähigkeit ist in die Technologie selbst eingebaut.

Total Addressable Market (TAM)

Segment	Geschätzter jährlicher Wert
US-Einzelhandelsretouren (falscher Artikel)	816 Mrd. \$
Umsatzverluste durch fehlgeschlagene Produktidentifikation	200+ Mrd. \$
SME-Arbeit in Callcentern (Identifikationsanteil)	50+ Mrd. \$
Beschaffungssineffizienz (RFP-Matching, Bestelleingabefehler)	100+ Mrd. \$
Adressierbarer Gesamtschmerz	>1 Billion \$ jährlich

Dies ist kein Feature – es ist eine Kategorie. Strukturelle Ausrichtung für Produktidentifikation wird derzeit von keiner einzigen Plattform adressiert. Der Markt ist fragmentiert zwischen Schlagwortsuche (Legacy), Embedding-Ähnlichkeit (Teillösung) und menschlicher Arbeit (teuer, inkonsistent). Kein bestehendes Produkt bietet deterministische, verifizierbare Multi-Generationen-Ausrichtung mit einer automatisierten Ontologie-Building-Pipeline.

Warum jetzt

Drei Bedingungen sind zusammengekommen, um SOAM in diesem Moment lebensfähig zu machen:

1. **LLM-Reife.** Große Sprachmodelle können jetzt zuverlässig Slot-basierte Merkmale aus natürlichen Sprachbeschreibungen extrahieren. Die „LLM-zu-Lexikon-Brücke“ – die einen flachen Produkteintrag in eine strukturierte Konzeptdefinition umwandelt – war vor fünf Jahren nicht möglich. Jetzt funktioniert sie.
2. **Embedding-Sättigung.** Cosinus-Ähnlichkeit + Reranking ist Basistechnologie. Jede E-Commerce-Plattform hat sie. Aber Unternehmen entdecken, dass Embeddings allein keine risikoreichen

Verifizierungen bewältigen können. Sie brauchen eine deterministische Schicht darüber.

3. **Retourenkostenkrise.** Die Retouren erreichten 2022 in den USA 816 Milliarden Dollar und wachsen schneller als die Einzelhandelsumsätze. Der Margendruck zwingt jeden Einzelhändler und Distributor, nach systematischen Lösungen zu suchen. „Retouren reduzieren, indem das richtige Teil vor dem Versand identifiziert wird“ ist ein Wertversprechen, das sofort eine Besprechung bekommt.

Verteidigungsfähigkeit: Warum SOAM schwer zu kopieren ist

Moat	Beschreibung
Daten-Moat	Jeder erfasste Katalog bereichert das Core Lexicon. Synonyme, Slot-Muster und domänenspezifische Begriffsklärungen sammeln sich an. Ein Wettbewerber müsste Tausende von Katalogen erfassen, um die gleiche Abdeckung zu erreichen. Dies ist ein kumulativer Vorteil, der mit jedem Kunden wächst.
Algorithmischer Moat	SOAM ist kein generischer LLM-Aufruf. Es ist eine deterministische Ausrichtungs-Engine mit Ontologie-Durchlauf, Slot-für-Slot-Verifizierung und ProofTrace-Erzeugung. Der Algorithmus ist in der SGF-Spezifikation veröffentlicht (Public Domain), aber die Implementierung in Produktionsqualität mit <1% Fehlerrate erfordert tiefes Verständnis des Ontologie-Durchlaufs, des Fingerprint-Vorfilters und der Gap-Analyse. Referenzcode ist Apache 2.0 – aber die Entwicklung eines zuverlässigen Dienstes darum herum ist nicht trivial.
Integrations-Moat	Sobald der Katalog eines Kunden im Business Inventory Lexicon angereichert ist, wird dieses Lexicon zur einzigen Quelle der Wahrheit für Produktidentifikation in Callcenter, E-Commerce, Beschaffung und Retouren. Ein Austausch

	bedeutet, jede SKU neu zu erfassen und neu auszurichten. Die Wechselkosten sind hoch.
Netzwerkeffekte (entstehend)	Mit der Erfassung weiterer Kataloge verbessert sich die Abdeckung des Core Lexicons für Synonyme, Domänenbegriffe und Slot-Muster. Ein neuer Kunde mit einem Automobilkatalog profitiert von den Automobilbegriffen, die bereits von früheren Automobilkunden grundiert wurden. Im Laufe der Zeit wird das Lexicon zum Industriestandard für strukturierte Produktbeschreibungen und schafft eine Eintrittsbarriere für jeden Wettbewerber, der bei Null anfängt.

Weg zum Einhorn

1. Pilot (8 Wochen, eine Vertikale, 2.000–10.000 SKUs) – ROI nachweisen.
2. Land and expand – an den Mittelstand innerhalb der Vertikale verkaufen, dann horizontal expandieren (Automotive → Luftfahrt → Bekleidung → Gesundheitswesen).
3. Plattform-Play – RFP-Matching, PO-Verifizierung und Bestandsabgleich als Add-ons auf demselben Lexicon starten.
4. Lexicon-Netzwerkeffekte – mit wachsender Akzeptanz wird das Core Lexicon zum Industriestandard. Neue Kunden wählen SOAM, weil es bereits „ihre Katalogsprache spricht“.

Der adressierbare Gesamtmarkt beträgt >1 Billion Dollar jährlichen Schmerz. Selbst die Erfassung von 0,1 % ergibt 1 Milliarde Dollar Umsatz. Dies ist kein Feature. Dies ist eine neue Kategorie.

10. Dieselbe Infrastruktur, alle vier Modi

Komponente	Chatbot (Modus 1)	Auto- Telefon (Modus 2)	Menschlicher Agent (Modus 3)	Hybrid (Modus 4)

Eingangswandler	Rohtext	STT-Engine	Agent tippt Merkmale (oder STT-Seitenwagen)	STT-Engine (zuerst automatisch, dann menschlich)
Merkmalsextraktion	LLM-Parser	Gleiches LLM	Gleiches LLM	Gleiches LLM
Level 1 (einfach)	Cosinus + LLM	Gleich	Gleich	Gleich
Level 2 (SOAM)	Vollständige strukturelle Ausrichtung	Gleich	Gleich	Gleich
Bestätigung / GapReport	Textanzeige	TTS-Vorlesen	Visuelle Anzeige + Agent liest dem Kunden vor	Auto: TTS; Eskaliert: Agent sieht GapReport
Mensch im Kreis?	Nein	Nein	Ja (Agent macht endgültige Bestätigung)	Nur bei GapReport oder Mehrdeutigkeit
SME-Eskalation nötig?	Niemals	Niemals	Selten (GapReport ersetzt SME)	Selten

Die zentrale Ingenieurstätigkeit – Lexika, Ausrichtungs-Engine, GapReport-Logik, ProofTrace-Generierung – wird einmal gebaut und in jeder Kombination von Modi eingesetzt. Sie können mit Modus 1 (Chatbot) beginnen und später Modus 2 (automatisches Telefon) hinzufügen, ohne neu zu bauen.

11. Was wir bauen

Wir bauen die Ausrichtungs-Engine und die Lexikon-Infrastruktur. Wir brauchen einen Partner, um dies in einer Produktkategorie zu pilotieren – Automobilteile, Luftfahrt-Hardware, Bekleidung oder ein beliebiger Katalog mit hoher SKU-Zahl und signifikanter Retourenquote.

Pilot-Umfang:

- Eine Produktkategorie (2.000–10.000 SKUs)
- Ein Einsatzmodus (wählen Sie aus den vier oben)
- Achtwöchige Implementierung
- Gemessene Ergebnisse: Retourenquotenreduzierung, Verbesserung der First-Call-Resolution, Steigerung der Verkaufskonversion, Reduzierung von SME-Eskalationen, Kosteneinsparungen in der Reverse Supply Chain

Über den Pilot hinaus: SOAM ist nicht auf Callcenter- oder Chatbot-Anwendungsfälle beschränkt. Dieselbe Architektur kann angewendet werden auf:

- Bulk-Einkaufslisten (z. B. ein Flottenwartungsmanager reicht eine Liste mit 50 Teilen ein – SOAM gleicht jeden Artikel automatisch, Slot für Slot, ohne menschliche Überprüfung ab).
- RFP-Matching (Abgleich eines Anbieterangebots mit einer strukturierten Anfrage, Erstellung eines verifizierten Compliance-Berichts).
- Elektronische Bestellungen / EDI-Positionsverifizierung (Normalisierung von Beschreibungen und Bestätigung von SKUs vor der Ausführung).

- Bestandsabgleich (Identifizierung von nicht etikettierten Retouren durch Abgleich visueller Merkmale mit dem Katalog).
- Jede Domäne, in der eine natürliche Sprachbeschreibung mit einem strukturierten Katalog abgeglichen werden muss.

Die Bitte: Wir suchen einen Callcenter-Betreiber, eine E-Commerce-Plattform, einen Teiledistributor oder ein Beschaffungssystem für den Pilot. Wir erfassen Ihren Katalog, bauen das Business Inventory Lexicon, integrieren mit Ihrem gewählten Modus und messen die Ergebnisse.

11a. Über das SGF-Projekt und den Autor

Dieses Papier basiert auf dem Symbol Grounding Framework (SGF) – einer umfassenden, mehrbändigen Spezifikation für grundiertes natürliches Sprachverständnis. Das SGF-Projekt definiert die Lexikon-Architektur, das Konzeptdefinitions-Schema und die SOAM (Structural Ontological Alignment Model) Ausrichtungs-Engine, die in diesem Papier beschrieben werden.

Die SGF-Spezifikation, einschließlich des Core Lexicon, aller Konzeptdefinitions-Schemas, des SOAM-Algorithmus und der vollständigen Architektur, ist in der Public Domain veröffentlicht. Referenz-Implementierungen sind unter der Apache-2.0-Lizenz verfügbar. Das Projekt umfasst auch eine Buchreihe und einen YouTube-Kanal mit technischen Durchläufen und Demonstrationen.

11b. Offene Grundlage, kommerzielle Chance

Der Autor hat die gesamte SGF-Architektur – Konzepte, Protokolle, Formate, Grammatiken und Betriebssystem-Designs – unwiderruflich in die Public Domain gestellt. Es ist keine Lizenz erforderlich. Es werden keine Tantiemen geschuldet. Der Autor hält keine Patentanmeldungen und hat sich verpflichtet, niemals welche einzureichen. Die Architektur ist für jeden kostenlos nutzbar.

Referenzcode, der vom Autor veröffentlicht wird, ist unter der Apache-2.0-Lizenz lizenziert, die die Nutzung, Änderung und Einbindung in kommerzielle

Produkte erlaubt. Die Lizenz enthält eine integrierte Patentfriedensklausel: Jeder, der den Code verwendet, trägt zu einer Gemeinschaft bei, die sich verpflichtet hat, keine Patente gegeneinander einzusetzen.

Sie brauchen den Code des Autors nicht. Die Spezifikationen in den RFC-Dokumenten und der Buchreihe sind vollständig genug, damit jeder seine eigenen Implementierungen in jeder Sprache erstellen kann.

Warum ist die Architektur offen? Das Ziel des Autors ist es, SGF zu einem globalen Standard dafür zu machen, wie Maschinen über Bedeutung nachdenken. Standards entstehen, wenn viele Menschen damit bauen und niemand sie kontrolliert. Tim Berners-Lee verschenkte die Protokolle des Webs. Vint Cerf und Bob Kahn verschenkten die Protokolle des Internets. Linus Torvalds veröffentlichte Linux unter Bedingungen, die verhinderten, dass ein einziges Unternehmen es besitzt. Jede grundlegende Technologie, die universell wurde, tat dies, weil ihr Schöpfer Adoption über Eigentum stellte.

Heißt das, niemand kann ein Geschäft aufbauen? Nein. Die Architektur ist das Fundament. Kommerzielle Produkte, die auf diesem Fundament aufbauen – wie das in diesem Papier beschriebene Produktidentifikationssystem – können closed-source, patentierbar und monetarisierbar sein. Der Autor selbst beabsichtigt, kommerzielle Produkte mit SGF zu bauen. Der Schlüssel ist, dass das Fundament neutral und offen bleibt. Jeder kann auf demselben Grundgestein konkurrieren.

Wie wird sich die Spezifikation weiterentwickeln? Der Autor hat sich zu einem Governance-Modell verpflichtet, das eine Übernahme verhindert. Zukünftige Änderungen an der Architektur werden von einem algorithmischen Prüfverfahren entschieden: Ein Ensemble von Front-End-Sprachmodellen bewertet jeden Vorschlag anhand des veröffentlichten Kanons. Der Prozess ist öffentlich. Keine Entität – egal wie gut ausgestattet – kann die Regeln umgehen, um einen proprietären Vorteil in den Standard zu erzwingen. Wenn jemals jemand versucht, die Architektur zu kapern, kann die

Gemeinschaft die Spezifikation von der letzten Public-Domain-Version forken.

Das Versprechen des Autors: „Ich habe die SGF-Architektur veröffentlicht und als Open Source bereitgestellt, weil die Welt eine Architektur für Symbol Grounding braucht, mehr als ich eine besitzen muss. Bauen Sie etwas.“

12. Fazit

Der Produktkatalog ist eine dichte Menge strukturierter Definitionen. Die Beschreibung des Kunden ist eine dünne, verrauschte Anfrage. Die Lücke zwischen ihnen ist das zentrale operative Problem jedes Unternehmens, das physische Produkte verkauft.

Aktuelle Ansätze behandeln diese Lücke als ein Ranking-Problem. Strukturelle Ausrichtung behandelt sie als ein Ausrichtungsproblem – Slot für Slot vergleichen, belegte Einschränkungen verifizieren und eine verifizierbare Aufzeichnung darüber erstellen, warum die Übereinstimmung richtig ist oder warum nichts übereinstimmt.

Das hier beschriebene System verwendet eine zweischichtige Architektur. Level 1 ist der einfache Ansatz – Cosinus-Ähnlichkeit plus LLM-Entscheider – schnell, günstig und ausreichend für risikoarme Anfragen. Level 2 ist SOAM – die strukturelle Ausrichtungs-Engine, die deterministische, verifizierbare Multi-Generationen-Tiefe für risikoreiche Entscheidungen hinzufügt. Das System wählt automatisch zwischen ihnen basierend auf der Fehlerkonsequenz.

Es gibt einen noch einfacheren Ansatz: eine kurze Liste präsentieren und den Kunden entscheiden lassen. Er funktioniert gut für aufmerksame Kunden und risikoarme Artikel. Er versagt jedoch, wenn der Kunde abgelenkt ist, die Artikel sich subtil unterscheiden oder die Bestellung eine Bulk-Liste ist. SOAM ist die Antwort für diese Fälle – und für jede Situation, in der die Kosten einer falschen Übereinstimmung höher sind als die Kosten der automatisierten Verifizierung.

Dieselbe Engine unterstützt alle vier Einsatzmodi – Chatbot, vollautomatisches Telefon, menschliche Agentenunterstützung und hybride Auto-zu-Mensch-Übergabe. Dieselbe Engine unterstützt Retouren. Dieselbe Engine transformiert automatisch Ihren flachen Produktkatalog in eine grundierte Ontologie, indem sie ein LLM zur Strukturvorschlag und SOAM zur Verifizierung einsetzt. Dieselbe Engine kann eine Bulk-Einkaufsliste, eine RFP oder eine elektronische Bestellung abgleichen – nicht nur eine einzelne Produkthanfrage.

Die Level-1/Level-2-Entscheidung stellt sicher, dass risikoarme Anfragen schnell und risikoreiche Anfragen verifiziert werden. Der GapReport verwandelt „keine Übereinstimmung“ von einer Sackgasse in eine strukturierte, korrigierbare Interaktion.

Das Retourenproblem – der Billionen-Dollar-Blindfleck in jeder Rückwärtsversorgungskette – ist mit derselben Infrastruktur lösbar. Ein retourniertes Teil, das positiv identifiziert werden kann, kann sortiert, aufbereitet und wiederverkauft werden. Ein retourniertes Teil, das nicht identifiziert werden kann, ist ein Totalverlust. Strukturelle Ausrichtung schließt die Identifikationslücke.

Aber der Wert geht weit über Retouren hinaus. Jede genaue Erstmal-Identifikation ist ein Verkauf, der sonst möglicherweise verloren gegangen wäre. Jeder Kunde, der diese Genauigkeit erlebt, wird zu einem treuen Wiederkehrer, der andere empfiehlt. Jeder Anruf, der keinen SME benötigt, spart das 3- bis 5-fache der Kosten einer Standardinteraktion. Jede RFP oder Bestellung, die automatisch abgeglichen wird, spart Tage manueller Überprüfung. Dieselbe Ausrichtungs-Engine, die Retouren verhindert, treibt auch Umsatz, baut Vertrauen auf und senkt die Betriebskosten im gesamten Unternehmen.

Ist das Over-Engineering? Für risikoarme Kataloge, ja. Für risikoreiche Produktidentifikation – wo ein einziger Fehler mehr kostet als die Investition in die Verifizierung – ist es genau das richtige Maß an Engineering. Das

System ist darauf ausgelegt, beides zu sein: einfach, wenn einfach ausreicht, und rigoros, wenn Rigorosität erforderlich ist.

Der Markt ist riesig – >1 Billion Dollar jährlicher Schmerz bei Retouren, Umsatzverlusten, SME-Arbeit und Beschaffungseffizienz – und das Timing ist richtig. LLMs machten die Merkmalsextraktion billig; Embeddings machten die Kandidatensuche schnell. Was gefehlt hat, ist eine deterministische Verifizierungsschicht. SOAM ist diese Schicht.

Die SGF-Architektur, die dies ermöglicht, ist frei, offen und neutral – von ihrem Schöpfer in die Public Domain gestellt. Kommerzielle Produkte, die auf diesem Fundament aufbauen, sind nicht nur möglich; sie sind der eigentliche Sinn.

Bauen Sie etwas.

—

James Lee Stäkelum

Kontaktinformationen

The Symbol Grounding Company

168 Gus Ledbetter Road, Calhoun, Louisiana |

JamesLeeStakelum@Proton.me | 318-732-9691

Vollständige SGF-Spezifikationen und Code:

github.com/SymbolGroundingFramework/SGF-manifest.

Sechsbändige SGF-Buchreihe: amazon.com/dp/B0H3FGSPK6.

YouTube: youtube.com/@The-Third-Protocol.